Perfis de municípios paulistas segundo indicadores integrados de criminalidade, efetividade da gestão municipal e vulnerabilidade socioeconômica

Bruno Hideo Ioneda[1], **Guilherme Samuel Lemos Segura**[1], **Higor Ranel Viani Lopes**[1]

[1]Escola de Artes, Ciências e Humanidades – Universidade de São Paulo (USP)
Rua Arlindo Bettio, 1000 – 03828-000 – São Paulo – SP – Brazil

brunoioneda@usp.br, guilhermesegura@usp.br, higor.ranel@usp.br

Abstract. *Crime and urban vulnerability vary widely across Brazilian municipalities, which limits the effectiveness of one-size-fits-all security policies. This study identifies and characterizes profiles of 644 municipalities in São Paulo state using 22 variables on crime, municipal management effectiveness, and socioeconomic conditions. K-means, Ward's hierarchical clustering, and DBSCAN were compared using internal validation metrics and stability tests. DBSCAN found a single cluster, and K-means with four profiles offered the best balance between stability and interpretability. Socioeconomic conditions and property crime are the main axes of separation, and management indicators distinguish urban municipalities with similar property crime levels, setting the core of Greater São Paulo apart from its periphery. In the external validation, the share of incidents on public streets differed across profiles ($\varepsilon^2 = 0.356$), although this variable correlates with variables used in the model. The profiles are robust to removing three variables with known measurement issues (ARI $\geq$ 0.849), but profiles 3 and 4 change under empirical Bayes smoothing of the crime rates (ARI of 0.551).*

Resumo. *A criminalidade e a vulnerabilidade urbana variam muito entre os municípios brasileiros, o que limita a eficácia de políticas de segurança padronizadas. Este estudo identifica e caracteriza perfis de 644 municípios paulistas a partir de 22 variáveis de criminalidade, efetividade da gestão municipal e condição socioeconômica. Foram comparados o K-means, o hierárquico de Ward e o DBSCAN por métricas de validação interna e testes de estabilidade. O DBSCAN encontrou um único grupo, e o K-means com quatro perfis ofereceu o melhor equilíbrio entre estabilidade e interpretabilidade. A condição socioeconômica e os crimes patrimoniais são os principais eixos de separação, e a gestão distingue municípios urbanos com criminalidade patrimonial semelhante, o que opõe o núcleo à periferia da Grande São Paulo. Na validação externa, a proporção de ocorrências em via pública diferiu entre os perfis ($\varepsilon^2 = 0{,}356$), embora essa variável se correlacione com as usadas na modelagem. Os perfis resistem à retirada de três variáveis de medição discutível (ARI $\geq$ 0,849), mas os perfis 3 e 4 mudam com a suavização bayesiana das taxas (ARI de 0,551).*

1. Introdução

A violência no Brasil deixou de ser um fenômeno exclusivamente metropolitano e se interiorizou pelo território nacional, concentrando-se em municípios com baixos níveis

de escolaridade e renda e com fragilidade do poder público [Soares Filho et al. 2024, Minamisava et al. 2009]. O estado de São Paulo apresenta uma trajetória singular nesse cenário, uma vez que seus municípios registraram queda expressiva dos homicídios ao longo das últimas duas décadas e, em 2018, o estado exibia a menor taxa de mortes violentas entre todas as unidades da Federação [Oliveira and Saiani 2021]. Essa média estadual, contudo, esconde uma heterogeneidade considerável. De fato, os 645 municípios paulistas vão de localidades com menos de 1.000 habitantes até a capital, maior metrópole do país, sendo que a mediana populacional é de 13.399 habitantes, e quase um quarto dos municípios tem menos de 5.000. Da mesma forma, na base construída neste trabalho, a taxa de crimes violentos letais intencionais (CVLI) no triênio 2023–2025 varia de zero a mais de 50 ocorrências por 100.000 habitantes-ano, e a de roubos, de zero a mais de 750. Compreender como essa heterogeneidade se organiza torna-se fundamental, portanto, para elaborar políticas de segurança que não sejam padronizadas para realidades tão distintas.

A literatura que fundamenta este trabalho aponta que a distribuição desigual da violência não é aleatória, mas sim articulada à estrutura social e institucional do território. A Teoria da Desorganização Social sustenta que a criminalidade se concentra em áreas marcadas por privação econômica, instabilidade residencial e heterogeneidade populacional, condições essas que enfraquecem os mecanismos informais de controle social [Shaw and McKay 1942]. Formulações posteriores associam a variação das taxas de crime violento à eficácia coletiva das vizinhanças, isto é, à coesão social aliada à disposição de intervir pelo bem comum [Sampson et al. 1997]. Ademais, a Teoria das Atividades Rotineiras amplia essa perspectiva ao explicar a ocorrência de crimes patrimoniais pela convergência espaço-temporal de ofensores motivados, alvos disponíveis e ausência de guardiões [Cohen and Felson 1979], o que ajuda a entender por que roubos e furtos tendem a se concentrar em centros urbanos mais densos e mais ricos, ao passo que crimes contra a vida se associam a tensões sociais e à baixa eficácia coletiva [Santos and Kassouf 2008].

No caso da capital paulista, a segregação socioespacial oferece uma chave de leitura decisiva, dado que o processo de urbanização da cidade produziu uma assimetria entre localização e condição social. Um estudo sobre a violência na capital mostra que os recursos públicos foram historicamente canalizados para a cidade rica, enquanto as periferias, formadas por autoconstrução, favelas e loteamentos sem infraestrutura, acumularam déficits de cidadania e de governabilidade [Hughes 2004]. Nesse quadro, os homicídios se concentraram nos distritos de maior exclusão social, e a ação do Estado nas periferias oscilou entre a ausência de investimentos e a presença repressiva. Esse estudo destaca, porém, que a governabilidade, entendida como a presença do Estado por meio de políticas sociais e da gestão cotidiana dos territórios, é um dos fatores que incidem na redução da violência, e reporta quedas mais acentuadas de homicídios nos distritos atendidos por programas sociais municipais do que nos demais. Embora formulado na escala intraurbana, esse argumento justifica, neste trabalho, incorporar à análise um indicador de efetividade da gestão municipal ao lado dos indicadores de vulnerabilidade socioeconômica. Afinal, se a capacidade institucional local influencia a relação entre exclusão e violência, ela deve integrar a caracterização dos perfis municipais juntamente com o crime e a pobreza.

Os dados necessários são abertos e provêm da SSP-SP [SSP-SP 2026], do Tri-

bunal de Contas do Estado, que apura o Índice de Efetividade da Gestão Municipal (IEGM) [TCE-SP 2026], e do IBGE [IBGE 2026b]. Para explorar a interação entre essas dimensões, métodos de clusterização são frequentemente utilizados. Na literatura, inclusive, há exemplos de segmentação de municípios de Pernambuco a partir de registros criminais para orientar políticas de segurança [Costa and Silva 2022], de identificação de dinâmicas espaciais do crime atreladas a fatores socioeconômicos no contexto norte-americano [Wang et al. 2013], de combinação de clusterização hierárquica e análise de componentes principais para relacionar homicídios a outras ocorrências policiais no Peru [González de la Rosa and Sánchez-Martínez 2026] e, mais recentemente, de aplicação de K-means e estatística espacial para caracterizar a colocalização de crimes e sinistros de trânsito em uma cidade média paulista [Rodrigues et al. 2026]. Paralelamente, no contexto paulista, um estudo econométrico mostra que as dimensões do desenvolvimento afetam de modo distinto os crimes contra a vida e contra o patrimônio [Oliveira and Saiani 2021], evidência que reforça a necessidade de tratar a criminalidade como fenômeno multidimensional.

Apesar do avanço dessas abordagens, poucos trabalhos investigam indicadores de criminalidade, efetividade institucional e condições socioeconômicas de forma simultânea no recorte paulista, e menos ainda comparam sistematicamente diferentes algoritmos de clusterização sobre uma mesma base. Por conseguinte, essa lacuna dificulta a compreensão de como fatores estruturais, institucionais e sociais se combinam para explicar a distribuição desigual da violência dentro do estado de São Paulo.

Diante disso, este trabalho tem como objetivo identificar e caracterizar perfis de municípios paulistas segundo indicadores integrados de criminalidade, efetividade da gestão municipal e vulnerabilidade socioeconômica. Para tanto, a pesquisa busca responder (i) se os três blocos de indicadores trazem informação complementar ou redundante sobre os municípios; (ii) qual algoritmo de clusterização, entre K-means, hierárquico aglomerativo e DBSCAN, produz a partição de melhor equilíbrio entre qualidade estatística e interpretabilidade; e (iii) que perfis emergem e como se relacionam com a literatura sobre desorganização social e segregação socioespacial. Ao responder a essas perguntas, o trabalho oferece uma contribuição dupla, que consiste em uma base pública integrada e documentada, com uma linha por município, e em uma comparação sistemática de algoritmos avaliada por múltiplas métricas de validação interna.

Este artigo responde às três perguntas. A Seção 2 reúne os trabalhos correlatos; a Seção 3 descreve o método. A Seção 4 apresenta e discute os resultados, de maneira a incluir os testes de robustez e a posição da capital. Por fim, a Seção 5 conclui o trabalho.

2. Trabalhos correlatos

Neste trabalho foram analisados nove trabalhos que dialogam com esta proposta, organizados em três grupos: estudos de estatística espacial sobre homicídios no Brasil, estudos que aplicam clusterização ou análise multivariada a dados criminais e estudos sobre determinantes da criminalidade nos municípios paulistas ou que forneceram o desenho metodológico adotado. A Tabela 1 sintetiza a comparação e a última parte da seção explicita as lacunas que este projeto busca preencher.

2.1. Estatística espacial sobre homicídios no Brasil

Um estudo ecológico abordando todos os municípios do Brasil no período de 2000 a 2018 associou taxas de homicídio e indicadores de violência, sociodemográficos e de segurança pública por meio de índices de Moran e regressão espacial com defasagem (*spatial lag*) [Soares Filho et al. 2024]. A proporção dos eventos violentos, a taxa de população negra, o inferior nível da educação, o fato de o município portar policiamento municipal foram identificados como principais fatores associados aos homicídios, e o estudo evidenciou o deslocamento do fenômeno da região Sudeste para o Norte e o Nordeste ao longo do período. Embora o trabalho cubra o território nacional, a análise se preocupa em focar nos homicídios apenas como resultado principal nas análises estatísticas. Além disso, não se preocupa em tentar agrupar os perfis de dados (clusterização) e deixa de fora do estudo indicadores de qualidade da gestão municipal.

Outro estudo, realizado em Goiânia no estado de Goiás, analisou a distribuição espacial e mortes de jovens (15 a 24 anos), de modo a identificar aglomerados de alto risco [Minamisava et al. 2009]. A comparação das características socioeconômicas dessas áreas com as demais regiões da cidade revelou uma forte associação entre homicídios e desigualdade social. Embora o estudo apresente uma metodologia robusta, a pesquisa se restringe a um único município, e não aplica clusterização multivariada nem incorpora indicadores de gestão pública.

2.2. Clusterização e análise multivariada de dados criminais

No Peru, uma pesquisa analisou a relação entre homicídios e 30 tipos de ocorrências policiais nas províncias do país, de maneira a combinar a análise de correlação, Análise de Componentes Principais (PCA) e clusterização hierárquica [González de la Rosa and Sánchez-Martínez 2026]. O resultado obtido foi a descoberta de três perfis criminais distintos que associam assassinatos a crimes econômicos. Essa metodologia é a que mais se aproxima do que propomos nesse trabalho. No entanto, o estudo deixa uma lacuna ao usar apenas um único algoritmo de agrupamento (sem testar ou validar com outras métricas) e, mais uma vez, deixa de fora os indicadores de gestão pública e de vulnerabilidade socioeconômica.

Nos Estados Unidos, um estudo propôs utilizar um modelo de mineração de dados espaciais (conhecido como GDPatterns) para mapear e otimizar hotspots de roubos residenciais [Wang et al. 2013]. Para entender esse cenário, os autores cruzaram variáveis como densidade populacional, taxas de prisão e execuções de hipotecas, de maneira a usar a clusterização hierárquica para resumir os padrões encontrados. Contudo, por ter sido aplicado a apenas uma cidade norte-americana, o foco recaiu quase exclusivamente sobre a otimização geométrica das áreas de risco de um único delito, sem criar perfis mais complexos (multivariados) que comparem múltiplos municípios.

No Brasil, uma pesquisa focada em Pernambuco agrupou os municípios a partir de indicadores criminais, de modo a agrupar cidades com padrões parecidos para ajudar a direcionar políticas de segurança [Costa and Silva 2022]. Este trabalho é o que mais se alinha à nossa proposta no que diz respeito à unidade de análise (o município) quanto ao foco no objetivo de apoiar a gestão pública. No entanto, a formação dos clusters se baseou estritamente em variáveis criminais e abriu uma lacuna ao não incorporar as condições socioeconômicas e institucionais dessas cidades na construção dos agrupamentos.

Em São Carlos (SP), um estudo recente analisou a sobreposição de crimes e sinistros de trânsito no entorno de pontos de ônibus, de modo a utilizar registros padronizados do SPSafe [Freitas et al. 2023] e do Infosiga-SP [Rodrigues et al. 2026]. A pesquisa buscou investigar a relação entre crimes e acidentes de trânsito ao redor de pontos de ônibus. A pesquisa aplicou clusterização por K-means e, por razões de utilidade prática, optou por reter três grupos (k = 3). Dessa abordagem, aproveitamos três grandes acertos para o nosso trabalho: primeiro, a forma como validaram os grupos usando informações que não entraram no modelo original (através do teste de Kruskal-Wallis e tamanho de efeito ε^2), de maneira a evitar vícios na análise. Segundo, o teste em diferentes tamanhos de área para garantir que o resultado era consistente. Terceiro, a clareza em não confundir perfis de dados com meros hotspots estatísticos. Apesar desses pontos fortes, o estudo difere do nosso por analisar apenas uma cidade, usar um único algoritmo, focar em contagens absolutas (e não taxas ajustadas) e deixar de fora indicadores socioeconômicos e de gestão.

2.3. Determinantes da criminalidade nos municípios paulistas e referências metodológicas

Em uma análise que abrangeu os 645 municípios paulistas, autores propuseram índices sintéticos de criminalidade que ponderam as ocorrências pela gravidade das penas, de modo a separar crimes contra a vida e contra o patrimônio em modelos dinâmicos entre 2007 e 2016 [Oliveira and Saiani 2021]. Os resultados evidenciaram efeitos heterogêneos do desenvolvimento: melhorias em emprego, renda e educação reduzem os crimes contra a vida, mas a dimensão de emprego e renda está associada a um aumento nos crimes patrimoniais, colaborando com a premissa de que roubos respondem a oportunidades de ganho e homicídios a tensões sociais [Santos and Kassouf 2008]. Para a nossa pesquisa, esse estudo traz duas validações importantes: as naturezas criminais devem ser analisadas de forma desagregada e o recorte estadual paulista é metodologicamente pertinente. Contudo, nossa proposta avança ao construir perfis municipais por meio de agrupamentos e ao utilizar indicadores de gestão municipal efetiva no lugar de índices genéricos de desenvolvimento como o IFDM.

Por fim, a estrutura passo a passo da nossa pesquisa foi inspirada em dois trabalhos recentes. O primeiro é um estudo de detecção de favelas via redes neurais, que estruturou a pesquisa de forma rigorosa, desde a seleção dos municípios-alvo até a avaliação espacial do modelo [da Silva et al. 2025]. O segundo investigou acidentes com caminhões em rodovias, estabelecendo um roteiro sólido de coleta, pré-processamento de dados e comparação de algoritmos [Soliani et al. 2024]. A principal ressalva é que ambos os estudos operam sob o paradigma do aprendizado supervisionado. Desse modo, adaptamos essa espinha dorsal lógica para o nosso contexto não supervisionado, de modo a substituir as tradicionais medições de acurácia por métricas de validação interna e de estabilidade dos agrupamentos.

Tabela 1. Síntese dos trabalhos correlatos. A última coluna indica se indicadores de gestão pública entram na análise.

Trabalho	Recorte / unidade	Dados	Método	Validação	Gestão?
Soares Filho (2024)	Brasil, 5.570 municípios	homicídios, sociodemografia, segurança	Moran, regressão espacial	inferência estatística	não
Minamisava (2009)	Goiânia, setores censitários	mortes de jovens, socioeconomia	varredura espacial (SaTScan)	significância do cluster	não
González (2026)	Peru, províncias	30 subtipos de ocorrência	correlação, hierárquico, PCA	qualitativa	não
Wang (2013)	cidade dos EUA, células espaciais	roubo residencial, covariáveis	GDPatterns, hierárquico	otimização de hotspots	não
Costa Silva (2022)	Pernambuco, municípios	indicadores criminais	clusterização	interna	não
Rodrigues (2026)	São Carlos (SP), pontos de ônibus	crimes, sinistros, linhas	K-means, Moran, LISA	cotovelo, silhueta, Kruskal–Wallis (ε^2), sensibilidade	não
Oliveira e Saiani (2021)	São Paulo, 645 municípios	índices de crime, IFDM	painel dinâmico (System-GMM)	testes de instrumentos	IFDM
Este trabalho	São Paulo, 644 municípios	9 taxas criminais, 6 socioeconômicas, 7 IEGM	K-means, Ward, DBSCAN	silhueta, CH, DB, estabilidade (ARI), ε^2 externo	**IEGM**

2.4. Lacunas identificadas

A revisão da literatura evidencia três lacunas principais que este estudo se propõe a resolver. Primeiramente, os trabalhos anteriores limitam-se à estatística espacial ou ao uso de um único algoritmo de clusterização, de modo a carecer de uma comparação sistemática entre diferentes técnicas com validação de estabilidade. Em segundo lugar, nenhum estudo integra, simultaneamente, indicadores de criminalidade, vulnerabilidade socioeconômica e efetividade da gestão pública na própria formação dos agrupamentos. Por fim, a literatura focada em São Paulo costuma ter um viés econométrico estadual ou uma visão espacial restrita a um único município. O que falta, e é essa a nossa contribuição, é um mapeamento que classifique todos os municípios paulistas, de maneira a cruzar a realidade criminal com a capacidade das prefeituras e o contexto social.

3. Método

O método está organizado em quatro etapas: obtenção e integração dos dados, análise exploratória e pré-processamento, aplicação e comparação de algoritmos de clusterização e caracterização dos perfis, seguidas de testes de robustez e do posicionamento da capital. Todo o *pipeline* foi implementado em Python (*pandas*, *scikit-learn*, *scipy*, *matplotlib*/*seaborn* e *geopandas*, este para os mapas).

3.1. Aquisição e integração dos dados

Foram utilizadas três fontes públicas municipais: da SSP-SP [SSP-SP 2026], os microdados de boletins de ocorrência de 2022 a 2025 (4.792.830 registros, dos quais 3.594.857 na janela de análise); do TCE-SP [TCE-SP 2026], o IEGM de 2022 a 2024, com o índice geral e suas sete dimensões, convertidos à escala ordinal de $C = 1$ a $A = 5$; e do IBGE, via SIDRA [IBGE 2026b], a população estimada de 2024, o PIB de 2023 e cinco indicadores do Censo 2022.

A integração foi feita exclusivamente pelo código IBGE, pois 532 dos 683 nomes de município da base da SSP apontam para mais de um código, já que a delegacia de

registro frequentemente não pertence ao município do crime. Assim, cada ocorrência foi atribuída ao município de *circunscrição*, isto é, ao local do fato.

A janela de 2023 a 2025 justifica-se pela transição do R.D.O. para o S.P.J., que tornou informatizada a consolidação dos dados a partir de 2023 [SSP-SP 2023b, SSP-SP 2023a]; pelo choque de mobilidade da pandemia, que afetou furtos e roubos, mas não homicídios; e pela indisponibilidade dos dados de 2026.

As ocorrências foram convertidas em taxas por 100 mil habitantes-ano, com a população de 2024 (ponto médio da janela) e exposição de três anos [Soares Filho et al. 2024]. Entraram nove naturezas criminais, incluindo o agregado de crimes violentos letais intencionais (CVLI), que reduz a proporção de zeros. Foram excluídos o roubo de carga, nulo em 57% dos municípios, os crimes culposos de trânsito e os registros de porte e apreensão, que refletem a intensidade do policiamento. O tráfico foi mantido como indício de organização criminosa, com ressalva na discussão.

A capital, fiscalizada pelo TCM-SP e sem nota do IEGM, foi marcada com `flag_sem_iegm` e excluída da modelagem, que utiliza 644 municípios. O índice geral do IEGM, redundante com suas dimensões (Spearman de 0,86), ficou apenas como contexto. Cada dimensão foi calculada como a média dos três exercícios, o que aumenta a variância do bloco. O espaço final reúne 22 variáveis: 9 de criminalidade, 6 socioeconômicas e 7 de gestão. Foram reservadas para uso posterior a proporção de ocorrências em via pública, destinada à validação externa, e a marcação `flag_pop_pequena`, que identifica os 149 municípios com menos de 5.000 habitantes, cujas taxas são instáveis [Assunção et al. 1998]. A base final tem uma linha para cada um dos 645 municípios e 54 colunas. Os únicos valores ausentes são o IEGM da capital e duas proporções auxiliares de veículos em 44 municípios (6,8%), sem nenhum veículo subtraído no período.

3.2. Análise exploratória e pré-processamento

A etapa exploratória abrangeu estatísticas descritivas, proporção de zeros, assimetria e correlação de Spearman, adotada em razão da não normalidade das taxas. Em pares de variáveis com $|\rho| > 0{,}85$, uma delas foi excluída. O pré-processamento consistiu em quatro etapas:

1. transformação $\log(1 + x)$ nas taxas e variáveis monetárias, assimétricas à direita, preservando as escalas originais dos percentuais e das notas ordinais;
2. padronização por escore-z (`StandardScaler`) nos 644 municípios modelados, essencial para algoritmos baseados em distância [Milligan and Cooper 1988]; essa escolha foi validada por comparação com alternativas (Seção 4.3);
3. ponderação por bloco, multiplicando cada variável por $1/\sqrt{n_b}$, para equalizar a influência de cada dimensão na variância total [Escofier and Pagès 1994];
4. aplicação de PCA sobre a matriz ponderada, tanto como diagnóstico de dimensionalidade quanto como espaço de entrada para o DBSCAN.

3.3. Clusterização e caracterização dos perfis

Para agrupar os municípios, aplicamos os algoritmos *K-means*, hierárquico de Ward e DBSCAN. O *K-means* e o Ward foram testados para $2 \leq k \leq 10$, executando o *K-means* 50 vezes com semente fixa para garantir reprodutibilidade. A qualidade técnica foi

avaliada pelo método do cotovelo e pelos índices de silhueta, Calinski-Harabasz e Davies-Bouldin. Para mitigar o excesso de dimensionalidade, o DBSCAN foi aplicado sobre 12 componentes principais (80% da variância), sob 14 configurações de parâmetros ($d + 1$ e $2d$ pontos mínimos, combinados com sete raios de vizinhança) [Hahsler et al. 2019, Sander et al. 1998].

Avaliamos a estabilidade das partições pelo Índice de Rand Ajustado (ARI), calculando a média das concordâncias ao alterar os recortes temporais (biênios de 2023–2025), ao excluir municípios com menos de 5.000 habitantes e, no caso do *K-means*, ao variar as inicializações aleatórias. A seleção do modelo final seguiu as seguintes regras, definidas a priori:

1. Para o DBSCAN, exigiu-se a formação de pelo menos dois grupos e menos de 20% de ruído.
2. Foram descartadas partições com algum grupo contendo menos de 5% dos municípios do estado.
3. Mantiveram-se apenas os agrupamentos entre os três melhores (*top* 3) segundo os índices de silhueta e Calinski-Harabasz.
4. As partições restantes foram ordenadas pelo índice de estabilidade, priorizando a melhor divisão com $k \geq 3$ para o aprofundamento dos perfis.
5. Em caso de empate, adotou-se a partição de interpretação prática mais clara.

Os perfis selecionados foram ordenados socioeconomicamente, do mais pobre ao mais rico, e ilustrados graficamente. A validação externa foi feita cruzando os grupos com a proporção de crimes em via pública [Rodrigues et al. 2026], mensurando a força da separação pelo teste de Kruskal-Wallis com tamanho de efeito (ε^2) [Rea and Parker 2014]. O mesmo teste foi usado para descrever as 22 variáveis originais, e os resultados finais foram projetados na malha municipal do IBGE [IBGE 2026a].

3.4. Testes de robustez e posição da capital

A partição escolhida foi submetida a três testes adicionais, sempre comparada à partição de referência pelo ARI. Temos que ARI igual ou superior a 0,80 indica que os perfis se mantêm. Já entre 0,65 e 0,80, que mudam em parte. Por fim, abaixo de 0,65, que dependem da alteração testada.

O primeiro teste avaliou a sensibilidade às três variáveis de medição discutível, a saber, a taxa de tráfico, o PIB per capita e a nota de planejamento do IEGM. Cada uma foi retirada separadamente e, depois, as três em conjunto, refazendo-se a padronização, o peso $1/\sqrt{n_b}$ do bloco afetado e o agrupamento.

O segundo teste substituiu as nove taxas criminais por taxas suavizadas pelo estimador bayesiano empírico global [Marshall 1991], que aproxima a taxa de cada município da taxa do conjunto na proporção da incerteza dela. Para cada natureza, sendo y_i as ocorrências e n_i as pessoas-ano do município, a taxa suavizada é

$$\tilde{r}_i = m + C_i\,(r_i - m), \qquad C_i = \frac{s^2}{s^2 + m/n_i},$$

em que $r_i = y_i/n_i$, $m = \sum y_i / \sum n_i$ e $s^2 = \sum n_i (r_i - m)^2 / \sum n_i - m/\bar{n}$, truncado em zero. A taxa do conjunto m foi calculada sobre os 644 municípios modelados. Além do

ARI em relação à referência, repetiu-se o teste de retirada dos municípios pequenos sobre a base suavizada.

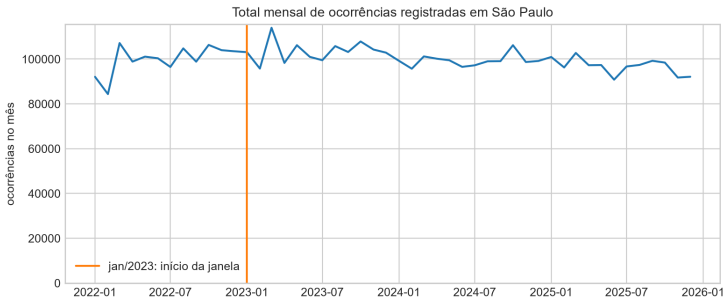
O terceiro procedimento posicionou a capital, excluída da modelagem por não ter IEGM. Os dados da capital foram transformados com a mesma escala dos 644 municípios, e calculou-se a distância ao centro de cada perfil nas 15 variáveis de criminalidade e condição socioeconômica. Para avaliar a confiabilidade dessa regra, a mesma classificação pelo centro mais próximo, sem o bloco de gestão, foi aplicada aos 644 municípios e comparada aos perfis originais.

4. Resultados e discussão

4.1. Validação da janela temporal

A Figura 1 detalha as ocorrências mensais de 2022 a 2025. Com o eixo vertical em zero para evitar distorções, nota-se a ausência de ruptura em janeiro de 2023. Na transição de 2022 para 2023, as naturezas criminais se dividiram entre cinco altas e cinco quedas (variação mediana de 6,2%, contra 5,8% nos anos posteriores). Uma falha por troca de sistema deslocaria todas as taxas em uma só direção. As exceções foram o CVLI (-10,2%) e estupro (+9,6%), crimes historicamente imunes a ruídos de registro. Portanto, o uso da janela de 2023 a 2025 está validado, de modo que 2022 venha a figurar apenas como controle metodológico.

Figura 1. Total mensal de ocorrências registradas no estado de São Paulo, 2022–2025. A linha vertical marca o início da janela de análise.



4.2. Análise exploratória

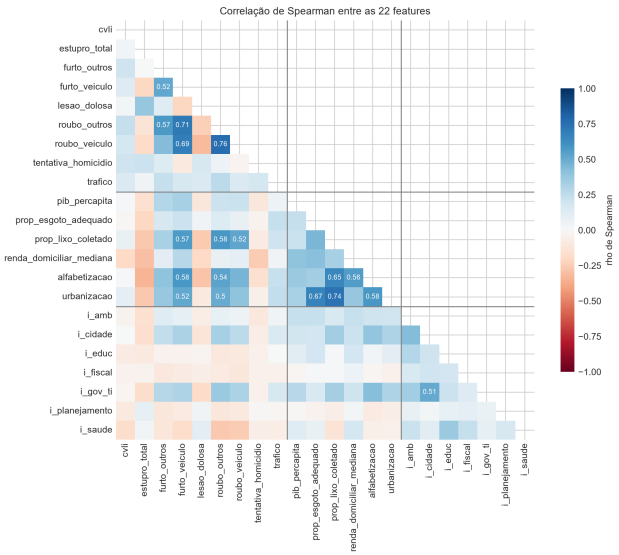
As nove taxas criminais dos 644 municípios apresentam forte assimetria à direita (de 1,1 a 3,9), com média sempre superior à mediana e máximos muito elevados, o que indica concentração em poucos municípios. A proporção de zeros varia de nenhum caso, para lesão dolosa e furto, a 20% para CVLI e 30% para roubo de veículo.

O efeito das populações pequenas se mostra evidente, pois sete das dez maiores taxas de CVLI ocorrem em municípios com menos de 10 mil habitantes, incluindo a máxima de 50,5 em Balbinos, com 3.963 habitantes. Já as dez maiores taxas de roubo estão na Grande São Paulo ou no litoral, como Santo André, Diadema e Guarujá. Como nenhum município aparece nas duas listas, a violência letal e a patrimonial apresentam dinâmicas territoriais distintas.

No bloco socioeconômico, o PIB per capita (de R$ 13 mil a R$ 580 mil, com picos em municípios industriais e energéticos) e a renda mediana (de R$ 700 a R$ 2.500)

foram mantidos em razão da baixa correlação entre si ($r = 0{,}41$). Na dimensão de gestão, os resultados concentram-se próximos ao limite inferior: 70% das cidades empatam em planejamento e nenhuma atinge o conceito geral A (283 com C, 261 com C+, 97 com B e 3 com B+), cenário alinhado aos achados de [Figueira et al. 2025]. Do ponto de vista estatístico, a transformação $\log(1+x)$ conteve a assimetria das taxas no intervalo de $-0{,}5$ a $+0{,}7$. O viés negativo remanescente reflete apenas a concentração de zeros, e não uma supercorreção.

Figura 2. Correlação de Spearman entre as 22 variáveis, ordenadas por bloco. As linhas separam os blocos e apenas $|\rho| \geq 0{,}5$ recebe rótulo.



A matriz de correlação (Figura 2) não apresenta pares acima de 0,85 (máximo de 0,76, entre subtipos de roubo), e por isso as 22 variáveis foram mantidas. Criminalidade e gestão são praticamente independentes ($|\rho|$ médio de 0,12), enquanto as correlações mais fortes ligam crimes patrimoniais a fatores socioeconômicos, como urbanização, alfabetização e coleta de lixo. O estupro correlaciona-se negativamente com o bloco socioeconômico, e o CVLI pouco se relaciona com as demais variáveis. O padrão reproduz a assimetria apontada pela literatura: crimes patrimoniais acompanham os polos de riqueza, ao contrário dos crimes contra a pessoa [Oliveira and Saiani 2021, Santos and Kassouf 2008].

4.3. Pré-processamento e dimensionalidade

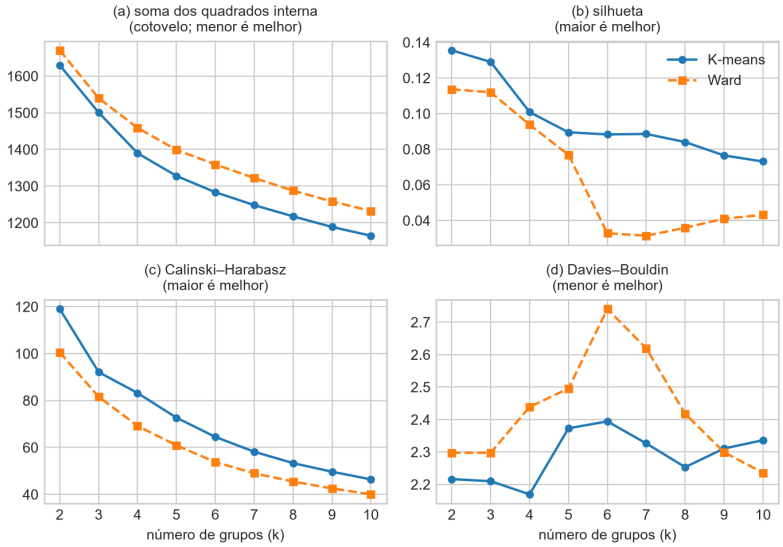
Sem ponderação, os blocos contribuiriam de forma desigual para a variância total: criminalidade com 40,9%, gestão com 31,8% e socioeconômico com 27,3%. O peso $1/\sqrt{n_b}$ garante que cada bloco contribua com exatamente um terço. Na comparação entre métodos de padronização, o `StandardScaler` mostrou-se superior. O `RobustScaler`, escolha preliminar, amplificou desproporcionalmente a nota de planejamento, que tem o mesmo valor em 70% dos municípios, e fez essa variável dominar a PC2. Já manter as notas originais de 1 a 5 reduziria o bloco de gestão a 2,3% da variância, esvaziando o principal diferencial da pesquisa. Como os valores extremos já haviam sido tratados pela transformação logarítmica, o `StandardScaler` foi a opção mais adequada.

O PCA sobre a matriz ponderada mostra que a PC1 responde por 24,6% da variância e a PC2 por 12,5%. São necessárias 12 das 22 componentes para atingir 80%, o que evidencia a ausência de estrutura de baixa dimensão e confirma, de forma independente da matriz de Spearman, que os três blocos não repetem informação. A PC1 funciona como eixo socioeconômico, reunindo no polo positivo alfabetização, urbanização, coleta de lixo, esgoto e renda, enquanto a PC2 contrapõe as notas de saúde e educação do IEGM às taxas de roubo. Projetados nesse plano, os 644 municípios formam uma nuvem contínua, sem grupos isolados, com os menos urbanizados no extremo negativo da PC1. A matriz final (644×22), transformada, padronizada e ponderada, serviu de entrada para a clusterização.

4.4. Comparação dos algoritmos

A Figura 3 reúne as medidas de qualidade do K-means e do Ward. As silhuetas são baixas em todas as partições, sendo que a maior, 0,136, ocorre no K-means com $k = 2$, e nenhuma atinge 0,25, o que é coerente com a distribuição contínua dos municípios observada na Seção 4.3. Silhueta e Calinski-Harabasz decrescem com k nos dois algoritmos, o K-means supera o Ward em ambas para todos os valores de k testados, e nenhuma das curvas de soma dos quadrados apresenta cotovelo nítido. O DBSCAN, por sua vez, encontrou um único grupo nas 14 configurações testadas, com ruído entre 0,3% e 23,8%, uma vez que a curva de distância ao k-ésimo vizinho cresce de forma gradual, sem o joelho que separaria regiões densas de ruído.

Figura 3. Medidas de qualidade do K-means e do Ward para $2 \leq k \leq 10$: (a) soma dos quadrados interna, (b) silhueta, (c) Calinski-Harabasz e (d) Davies-Bouldin.



A aplicação da regra de decisão excluiu o DBSCAN no primeiro passo e, no segundo, as partições do K-means com $k \geq 7$ e do Ward com $k \geq 8$, que continham grupos com menos de 5% dos municípios. No terceiro passo, restaram $k = 2$, 3 e 4 nos dois algoritmos (Tabela 2). Quanto à estabilidade, o K-means superou o Ward para todos os valores de k. O índice do K-means variou de 0,447 a 0,850, e o do Ward, de 0,311 a 0,477. A divisão mais robusta é a do K-means com $k = 2$ (0,850). Entre as partições com $k \geq 3$,

o K-means com $k = 4$ (0,761) e com $k = 3$ (0,743) ficaram empatados pela tolerância de 0,05. Nos dois casos, o teste mais exigente foi a retirada dos municípios pequenos, com ARI próximo de 0,5, o que indica que parte das fronteiras entre os grupos depende desses municípios.

Tabela 2. Candidatos que passaram nos filtros de tamanho e de qualidade da regra de decisão. As colunas de ARI comparam cada partição com a obtida nas subjanelas e sem os municípios pequenos. Estab. é a média dos três, e Sementes, o ARI médio entre execuções do K-means com sementes distintas.

					ARI				
Algoritmo	k	Silh.	CH	DB	2023-24	2024-25	s/ peq.	Estab.	Sementes
K-means	2	0,136	119,0	2,216	0,897	0,909	0,744	0,850	0,981
K-means	3	0,129	92,1	2,210	0,818	0,901	0,512	0,743	0,451
K-means	4	0,101	83,2	2,169	0,891	0,912	0,480	0,761	0,929
Ward	2	0,114	100,5	2,297	0,432	0,509	0,441	0,461	–
Ward	3	0,112	81,6	2,297	0,443	0,549	0,440	0,477	–
Ward	4	0,094	69,2	2,439	0,324	0,346	0,315	0,329	–

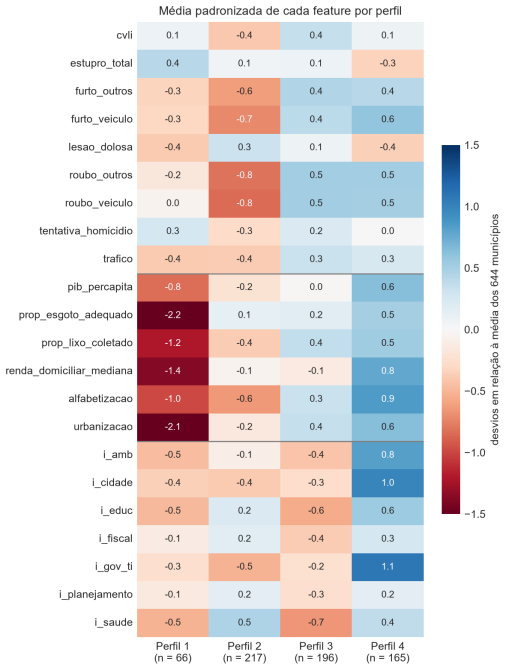
Entre as partições empatadas, adotou-se o *K-means* com $k = 4$ por dois motivos. Primeiro, só com quatro grupos o bloco de gestão separa municípios socioeconomicamente semelhantes: os perfis 3 e 4 (Seção 4.5), distintos sobretudo pelo IEGM, fundem-se em grande parte quando $k = 3$. Segundo, a partição com $k = 4$ é estável entre inicializações (ARI de 0,929, contra 0,451 com $k = 3$). A silhueta favorece ligeiramente $k = 3$ (0,129 contra 0,101), mas ambos os valores indicam estrutura fraca, e por isso prevaleceu a utilidade interpretativa, como em [Rodrigues et al. 2026]. Os perfis 1 e 2 se mantêm nas duas partições (65 de 66 e 214 de 217 municípios), de modo que sua leitura independe de k.

4.5. Perfis

A Figura 4 mostra a média padronizada de cada variável nos quatro perfis, numerados em ordem crescente de condição socioeconômica; as medianas citadas a seguir estão em unidades originais.

O perfil 1 (66 municípios) tem a pior condição socioeconômica do estado, com esgoto adequado ($-2{,}2$ desvios), urbanização ($-2{,}1$; mediana de 60,8%, contra 90,5% no estado) e renda ($-1{,}4$; R$ 942, contra R$ 1.200) muito abaixo da média, estupro e tentativa de homicídio levemente acima dela e crimes patrimoniais iguais ou inferiores a ela. O perfil 2 (217) concentra os municípios pequenos (53,5% com menos de 5.000 habitantes), com condição socioeconômica próxima da média e as menores taxas de crimes patrimoniais (roubo mediano de 10,3 por 100 mil hab.-ano, contra 27,9 no estado). Os perfis 3 (196) e 4 (165), os mais urbanizados, compartilham crimes patrimoniais acima da média (roubo mediano de 46,2 e 51,4), mas divergem na gestão: o perfil 3 fica abaixo da média sobretudo em saúde ($-0{,}7$) e educação ($-0{,}6$), enquanto o perfil 4 supera a média nas sete dimensões do IEGM, além de renda e alfabetização; o IEGM geral mediano, que não é variável do modelo, é de 1,00 no perfil 3 e de 2,00 no perfil 4. Entre os dois, a di-

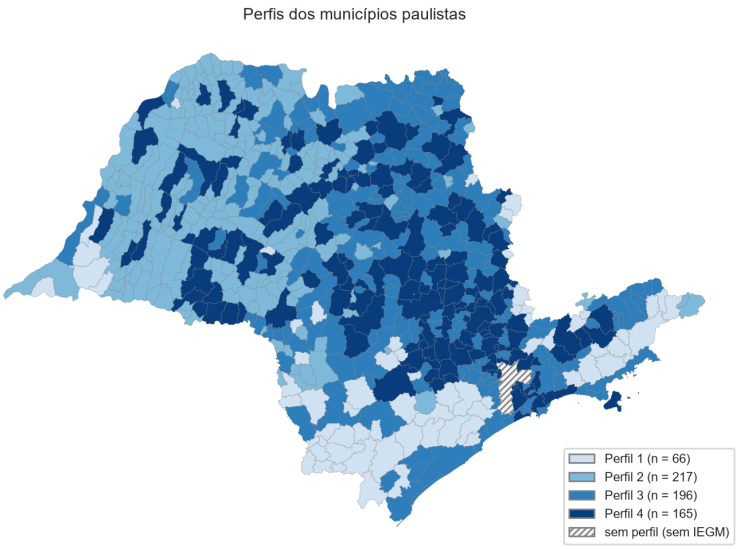
Figura 4. Média padronizada das variáveis por perfil



Nota: valores em desvios-padrão em relação à média dos 644 municípios; positivos em azul, negativos em vermelho. As linhas separam os blocos de criminalidade, socioeconômico e de gestão.

ferença chega a 1,3 desvio nas dimensões de governança de TI e de proteção das cidades, contra 0,9 na renda e quase nenhuma em roubo e furto.

Figura 5. Perfis dos municípios paulistas. A capital, fora da modelagem por não ter IEGM, aparece hachurada.



Os perfis têm geografia nítida (Figura 5). O perfil 1 concentra-se no Vale do Ribeira, na região de Itapeva e no extremo leste, e o perfil 2 no oeste e noroeste. O perfil 3 reúne a periferia da Grande São Paulo (como Carapicuíba e Francisco Morato), a maior

parte do litoral e cidades médias do Vale do Paraíba. O perfil 4 reúne os polos regionais do interior (como Campinas, Ribeirão Preto e São José do Rio Preto) e o núcleo da Grande São Paulo e da Baixada Santista (como Santo André, Guarulhos e Santos).

Na validação externa, a proporção de ocorrências em via pública diferiu entre os perfis com efeito relativamente forte ($H = 229{,}2$; $p < 0{,}001$; $\varepsilon^2 = 0{,}356$), com medianas de 33,1%, 30,0%, 41,3% e 48,4% nos perfis 1 a 4. Parte desse efeito, porém, reflete diferenças já presentes na modelagem, pois a variável correlaciona-se com a taxa de roubo ($\rho = 0{,}68$) e com furto, roubo de veículo, coleta de lixo, alfabetização e urbanização (0,60 a 0,65). As variáveis que mais separam os perfis são a alfabetização ($\varepsilon^2 = 0{,}494$), a urbanização (0,490) e a taxa de roubo (0,428), enquanto os crimes contra a pessoa separam pouco (ε^2 entre 0,030 e 0,090).

4.6. Robustez dos perfis e posição da capital

A Tabela 3 mostra que a retirada das três variáveis de medição discutível não altera os perfis. O menor ARI, de 0,849, ocorre com as três retiradas em conjunto, situação em que 37 dos 644 municípios mudam de perfil, 20 deles do perfil 4 para o perfil 3. Sem o PIB per capita, 33 municípios mudam de perfil, a maior parte saindo do perfil 4. Em todos os testes, o perfil 1 manteve pelo menos 65 dos seus 66 municípios.

Tabela 3. Testes de robustez. O ARI compara cada partição com a de referência; a última coluna traz o número de municípios que mudaram de perfil.

Teste	ARI	Municípios que mudaram
Sem a taxa de tráfico	0,948	12
Sem o PIB *per capita*	0,864	33
Sem a nota de planejamento	0,904	23
Sem as três variáveis	0,849	37
Taxas suavizadas (644 municípios)	0,551	113
Taxas suavizadas (149 pequenos)	0,713	12
Taxas suavizadas (495 demais)	0,504	101
Sem os pequenos, taxas originais	0,480	–
Sem os pequenos, taxas suavizadas	0,822	–

Com as taxas suavizadas, o ARI em relação à partição de referência é de 0,551, e 113 municípios mudam de perfil (Tabela 3). Pelo critério adotado, os perfis dependem do tratamento dado às taxas. A mudança não se concentra nos municípios pequenos, pois apenas 12 dos 113 têm menos de 5.000 habitantes, e o ARI é de 0,713 entre os 149 pequenos e de 0,504 entre os 495 demais. Os perfis 1 e 2 praticamente se mantêm (65 de 66 e 213 de 217 municípios), enquanto os perfis 3 e 4 perdem 65 e 43 municípios, a maior parte para o perfil 2, que passa de 217 para 304 municípios. Os municípios que deixam os perfis 3 e 4 têm taxas de roubo menores que os que permanecem (medianas de 26,96 e 33,33 contra 58,39 e 61,96 por 100 mil hab.-ano) e populações menores. Por outro lado, a partição suavizada é mais estável à retirada dos municípios pequenos (ARI de 0,822, contra 0,480) e tem silhueta ligeiramente maior (0,115, contra 0,101).

Nas 15 variáveis de criminalidade e condição socioeconômica, a capital fica mais próxima do perfil 4 (distância de 1,304) e, em segundo lugar, do perfil 3 (1,590), contra 2,453 e 3,030 dos perfis 2 e 1. Aplicada aos 644 municípios, a mesma regra devolve o perfil original de 78,1% deles, mas apenas de 64,8% do perfil 3 e de 70,9% do perfil 4, de modo que a distinção entre os dois perfis mais próximos da capital é a parte menos confiável do resultado. Além disso, a taxa de roubo da capital (952,88 por 100 mil hab.-ano) supera o máximo observado entre os 644 municípios (751,84), e nos furtos e no roubo de veículo ela fica bem acima da média de todos os perfis. A posição da capital é, portanto, uma aproximação, e não uma classificação.

4.7. Discussão

Como os municípios formam um contínuo, sem regiões densas separadas por regiões vazias, os algoritmos traçam limites operacionais úteis, e não descobrem grupos naturalmente isolados, o que explica o resultado do DBSCAN e justifica o critério de utilidade interpretativa na escolha entre as partições empatadas [Rodrigues et al. 2026]. Os testes de robustez mostram que os perfis não dependem das três variáveis de medição discutível, mas que a fronteira entre os perfis 3 e 4 e o perfil 2 depende do tratamento das taxas criminais.

Os perfis dialogam com a literatura em três pontos. Primeiro, os crimes patrimoniais acompanham a urbanização e a renda e se concentram nos perfis 3 e 4, o que é compatível com a Teoria das Atividades Rotineiras, segundo a qual centros mais densos e mais ricos reúnem mais alvos disponíveis [Cohen and Felson 1979], e com o efeito do desenvolvimento sobre os crimes contra o patrimônio observado nos municípios paulistas [Oliveira and Saiani 2021]. Segundo, o perfil 1, de maior privação, é o único em que crimes contra a pessoa, como estupro e tentativa de homicídio, superam a média enquanto os patrimoniais ficam abaixo dela, padrão consistente com a associação entre privação, tensões sociais e crimes contra a vida [Shaw and McKay 1942, Santos and Kassouf 2008]. Ainda assim, o CVLI separa pouco os perfis ($\varepsilon^2 = 0{,}057$), o que indica que a violência letal, no recorte municipal paulista, não se organiza pelas mesmas dimensões que o crime patrimonial. Terceiro, os perfis 3 e 4 têm criminalidade patrimonial semelhante e se distinguem sobretudo pela gestão e, em menor grau, pela renda, e na Grande São Paulo essa distinção opõe o núcleo metropolitano à sua periferia. O resultado aproxima, na escala intermunicipal, o argumento de que as periferias acumulam déficits de governabilidade [Hughes 2004], embora a análise seja descritiva e não permita afirmar que a gestão cause diferenças na criminalidade.

Os resultados devem ser lidos à luz de seis limitações. Primeiro, os anos de referência diferem entre as fontes (Censo de 2022, PIB de 2023 e crimes de 2023 a 2025), em razão do calendário de publicação de cada órgão. Segundo, a capital ficou fora da modelagem por não ter IEGM, o que retira da análise a cidade com mais ocorrências do estado; sua aproximação ao perfil 4 é apenas indicativa, dada a extrapolação na taxa de roubo e a separação fraca entre os perfis 3 e 4 sem o bloco de gestão. Terceiro, as taxas dos 149 municípios com menos de 5.000 habitantes são instáveis [Assunção et al. 1998], e a retirada desses municípios foi o teste de estabilidade mais exigente, com ARI de 0,480 para a partição escolhida. A suavização bayesiana dessas taxas torna a partição mais estável (ARI de 0,822), mas altera a composição dos perfis 3 e 4 em municípios de todos os portes (ARI de 0,551), de modo que esses dois perfis devem ser lidos como dependentes

do tratamento dado às taxas criminais. Quarto, a taxa de tráfico reflete também a ação policial, o PIB per capita é inflado por polos industriais isolados e a nota de planejamento do IEGM empata 70% dos municípios, embora a retirada dessas variáveis não altere os perfis (ARI de 0,849 a 0,948). Quinto, a variável de validação externa se correlaciona com as taxas de roubo e com a urbanização, de modo que a validação é apenas parcialmente independente da modelagem. Por fim, as silhuetas baixas indicam que muitos municípios estão próximos da fronteira entre dois perfis, e a subnotificação dos crimes patrimoniais pode afetar a análise caso varie muito entre os municípios.

5. Conclusão

Este trabalho identificou quatro perfis de municípios paulistas a partir de indicadores integrados de criminalidade, efetividade da gestão municipal e condição socioeconômica. Os três blocos trazem informação complementar, e o K-means com quatro grupos ofereceu o melhor equilíbrio entre qualidade e estabilidade, enquanto o DBSCAN não encontrou grupos em uma distribuição contínua. Os perfis separam-se sobretudo pela condição socioeconômica e pelo crime patrimonial, e a gestão distingue municípios urbanos de criminalidade semelhante. Em conjunto, os resultados indicam que uma política de segurança única dificilmente atenderia aos municípios paulistas: no perfil 1, a privação sugere priorizar a redução da vulnerabilidade social, e nos perfis 3 e 4 a capacidade institucional surge como dimensão a considerar. Por se tratar de uma análise descritiva, essas leituras podem orientar o planejamento, mas não estimam o efeito de intervenções. Como trabalhos futuros, sugere-se repetir a caracterização com as taxas suavizadas, avaliar versões locais do estimador bayesiano e incorporar a capital caso o TCM-SP disponibilize um indicador comparável ao IEGM.

Referências

Assunção, R. M., Barreto, S. M., Guerra, H. L., and Sakurai, E. (1998). Mapas de taxas epidemiológicas: uma abordagem Bayesiana. *Cadernos de Saúde Pública*, 14(4):713–723.

Cohen, L. E. and Felson, M. (1979). Social change and crime rate trends: a routine activity approach. *American Sociological Review*, 44(4):588–608.

Costa, J. C. O. R. and Silva, M. M. (2022). A clustering-based approach for identifying groups of municipalities to support the direction of public security policies. *Pesquisa Operacional*, 42.

da Silva, J. P., Rodrigues-Jr, J. F., and de Albuquerque, J. P. (2025). On the power of CNNs to detect slums in Brazil. *Computers, Environment and Urban Systems*, 121:102306.

Escofier, B. and Pagès, J. (1994). Multiple factor analysis (AFMULT package). *Computational Statistics & Data Analysis*, 18(1):121–140.

Figueira, L. A. C., Mello, A. C. O., and Tristão, D. G. (2025). O IEG-M e i-Plan: do desempenho crítico à boa governança como caminho para a gestão municipal. *Cadernos da Escola Paulista de Contas Públicas*, 1(15):301–325.

Freitas, J. B., Clarindo, J. P., and Aguiar, C. D. (2023). SPSafe: um dataset sobre dados de criminalidade no estado de São Paulo. In *Anais do V Dataset Showcase Workshop (DSW)*, pages 48–57, Porto Alegre. Sociedade Brasileira de Computação.

González de la Rosa, L. A. and Sánchez-Martínez, L. J. (2026). Analyzing the relationship between homicides and police reports in Peru: a multivariate and cluster analysis with a spatial approach. *International Journal of Law, Crime and Justice*, 85:100859.

Hahsler, M., Piekenbrock, M., and Doran, D. (2019). dbscan: fast density-based clustering with R. *Journal of Statistical Software*, 91(1):1–30.

Hughes, P. J. A. (2004). Segregação socioespacial e violência na cidade de são paulo: referências para a formulação de políticas públicas. *São Paulo em Perspectiva*, 18(4):93–102.

IBGE (2026a). API de malhas geográficas – versão 3. `https://servicodados.ibge.gov.br/api/docs/malhas?versao=3`. Acesso em: 7 out. 2026.

IBGE (2026b). Sistema IBGE de recuperação automática – SIDRA. `https://sidra.ibge.gov.br`. Acesso em: 15 ago. 2026.

Marshall, R. J. (1991). Mapping disease and mortality rates using empirical Bayes estimators. *Journal of the Royal Statistical Society: Series C (Applied Statistics)*, 40(2):283–294.

Milligan, G. W. and Cooper, M. C. (1988). A study of standardization of variables in cluster analysis. *Journal of Classification*, 5(2):181–204.

Minamisava, R., Nouer, S. S., de Morais Neto, O. L., Melo, L. K., and Andrade, A. L. S. S. (2009). Spatial clusters of violent deaths in a newly urbanized region of Brazil: highlighting the social disparities. *International Journal of Health Geographics*, 8(66).

Oliveira, L. F. B. and Saiani, C. C. S. (2021). Índices de criminalidade nos municípios paulistas: efeitos heterogêneos do desenvolvimento econômico nos crimes contra a vida e contra o patrimônio. *Revista Brasileira de Estudos Regionais e Urbanos*, 15(2):275–309.

Rea, L. M. and Parker, R. A. (2014). *Designing and conducting survey research: a comprehensive guide*. Jossey-Bass, San Francisco, 4 edition.

Rodrigues, L. R., Pitombo, C. S., Cunha, A. L. B. N., Larocca, A. P. C., and Ferraz, A. C. P. (2026). Spatial association and hotspot co-location of crime and road traffic injuries around bus stops: a medium-sized Brazilian city case study. *Latin American Transport Studies*, 4:100067.

Sampson, R. J., Raudenbush, S. W., and Earls, F. (1997). Neighborhoods and violent crime: a multilevel study of collective efficacy. *Science*, 277(5328):918–924.

Sander, J., Ester, M., Kriegel, H.-P., and Xu, X. (1998). Density-based clustering in spatial databases: the algorithm GDBSCAN and its applications. *Data Mining and Knowledge Discovery*, 2(2):169–194.

Santos, M. J. and Kassouf, A. L. (2008). Estudos econômicos das causas da criminalidade no Brasil: evidências e controvérsias. *EconomiA*, 9(2):343–372.

Shaw, C. R. and McKay, H. D. (1942). *Juvenile Delinquency and Urban Areas*. University of Chicago Press, Chicago.

Soares Filho, A. M., Vasconcelos, C. H., Cunningham, M., Ribeiro, A. L. P., Naghavi, M., and Malta, D. C. (2024). Spatial association of homicide rate with violence, so-

ciodemographic, and public security factors: global burden of disease study 2018 for municipalities in Brazil. *Public Health*, 227:16–23.

Soliani, R. D., Argoud, A. R. T. T., Santiago, F., Lopes, A. V. B., and Emekwuru, N. (2024). Catastrophic causes of truck drivers' crashes on Brazilian highways: mixed method analyses and crash prediction using machine learning. *Multimodal Transportation*, 3:100173.

SSP-SP (2023a). Nota técnica: grupo de trabalho para revisão dos indicadores criminais. https://www.ssp.sp.gov.br/assets/download/RELATORIO_FINAL_20DEZ23_NotaIII_NotaIV.pdf. Acesso em: 20 set. 2026.

SSP-SP (2023b). Relatório final do grupo de trabalho para revisão dos indicadores criminais. https://www.ssp.sp.gov.br/assets/download/NotaTecnica_%20Resolucao35-2023.pdf. Acesso em: 20 set. 2026.

SSP-SP (2026). Dados estatísticos mensais. https://www.ssp.sp.gov.br/estatistica/dados-mensais. Acesso em: 15 ago. 2026.

TCE-SP (2026). Índice de efetividade da gestão municipal (IEGM). https://www.tce.sp.gov.br/iegm. Acesso em: 15 ago. 2026.

Wang, D., Ding, W., Lo, H., Morabito, M., Chen, P., Salazar, J., and Stepinski, T. (2013). Understanding the spatial distribution of crime based on its related variables using geospatial discriminative patterns. *Computers, Environment and Urban Systems*, 39:93–106.